

Resolução da Lista 3 - Análise de Dados Longitudinais

Helen Lourenço e Vitor Kroeff

Questão 1

a)

```
dados <- tibble(foreign::read.dta("toenail.dta"))
ajuste_gee <- geeglm(y ~ trt * month - trt, family = binomial(link = "logit"),
                    data = dados, id = id, corstr = "exchangeable")
```

b)

```
exp(ajuste_gee$coefficients)
```

(Intercept)	month	trt:month
0.5608934	0.8425524	0.9252438

O coeficiente β_2 está relacionado ao efeito do tempo no grupo de tratamento A (ou controle). O expoente e^{β_2} representa uma razão de chances. Essa razão de chances indica que, no grupo A, o coeficiente está associado a uma redução na probabilidade de ocorrência de onicólise com o passar dos meses.

c)

O coeficiente β_3 está associado a interação entre o tratamento B e o tempo em meses. Assim como na alternativa anterior, vemos que $e^{\beta_3} = 0,925$ está associado a uma redução das chances de ocorrência de onicólise com o passar dos meses, porém uma redução menor que a do grupo controle.

d)

Podemos observar o `summary` do modelo ajustado como sendo:

```
summary(ajuste_gee)
```

Call:

```
geeglm(formula = y ~ trt * month - trt, family = binomial(link = "logit"),
       data = dados, id = id, corstr = "exchangeable")
```

Coefficients:

	Estimate	Std.err	Wald	Pr(> W)	
(Intercept)	-0.57822	0.13041	19.661	9.25e-06	***
month	-0.17132	0.02957	33.574	6.86e-09	***
trt:month	-0.07770	0.05379	2.086	0.149	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Correlation structure = exchangeable

Estimated Scale Parameters:

	Estimate	Std.err
(Intercept)	1.088	0.5265

Link = identity

Estimated Correlation Parameters:

	Estimate	Std.err
alpha	0.4217	0.2203

Number of clusters: 294 Maximum cluster size: 7

Com base no p-valor associado ao β_3 , não parece ter uma diferença significativa entre os tratamentos aplicados nos Grupos A e B. Também com base nos coeficientes do modelos, podemos observar que essa chance de desenvolver uma onicólise sereve diminui com o passar dos meses.

e)

```
ajuste_misto <- lme4::glmer(
  formula = y ~ month + trt:month + (1 | id),
  family = binomial(link = "logit"),
  data = dados)
```

f)

Como o efeito aleatório está apenas no intercepto, vimos a seguinte relação aproximada entre os coeficientes do modelo marginal e aqueles do modelo de efeitos aleatórios.

$$\beta_M = \frac{\beta_{EA}}{\sqrt{1 + \frac{16\sqrt{3}}{15\pi}\sigma_b^2}}$$

```
var_bi <- lme4::VarCorr(ajuste_misto)
var_bi
```

```
Groups Name          Std.Dev.
id      (Intercept) 4.54
```

```
var_bi <- sqrt(as.numeric(var_bi)) # Conversão para numérico
fator <- sqrt(1 + (16*sqrt(3)/(15*pi)*var_bi))
fator
```

```
[1] 1.916
```

Podemos comparar as magnitudes dos efeitos da seguinte forma:

```
b.gee <- summary(ajuste_gee)$coef[,1]
b.lme <- summary(ajuste_misto)$coef[,1]
p.gee <- summary(ajuste_gee)$coef[,4]
p.lme <- summary(ajuste_misto)$coef[,4]
round(cbind(b.gee, or.gee = exp(b.gee), p.gee, b.lme, or.lme = exp(b.lme), p.lme,
  razao.b = b.lme/b.gee), 3)
```

	b.gee	or.gee	p.gee	b.lme	or.lme	p.lme	razao.b
(Intercept)	-0.578	0.561	0.000	-2.649	0.071	0.00	4.581
month	-0.171	0.843	0.000	-0.396	0.673	0.00	2.309
month:trt	-0.078	0.925	0.149	-0.146	0.865	0.03	1.873

Podemos observar estimativas maiores para o modelo misto em relação ao GEE, mas com o mesmo sinal, indicando uma concordância dos efeitos das variáveis.

g)

```
knitr::kable(  
  exp(summary(ajuste_misto)$coef))
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.0707	2.031	0.0238	1.00
month	0.6733	1.047	0.0002	1.00
month:trt	0.8646	1.069	0.1134	1.03

A interpretação é muito próxima a do modelo GEE, onde β_2 está associada a variação no mês no grupo A (controle), porém está sendo levado em conta a variação de cada paciente do grupo A por conta do efeito aleatório no intercepto.

h)

i)

j)

Questão 2

a)

```
ajuste_gee_ind <- geeglm(response ~ group * time, data = dados_rats,  
  id = subject, corstr = "independence")  
  
ajuste_gee_simetria <- geeglm(response ~ group * time, data = dados_rats,  
  id = subject, corstr = "exchangeable")  
  
ajuste_gee_ar1 <- geeglm(response ~ group * time, data = dados_rats,  
  id = subject, corstr = "ar1")  
  
ajuste_gee_unstructured <- geeglm(response ~ group * time, data = dados_rats,  
  id = subject, corstr = "unstructured")
```

b)

Nos ajustes realizados na alternativa anterior $Y_{ij}(\text{response})$ segue uma distribuição Normal com diferentes formas de estimar a matriz de corelação. Dentre as ajustas estão (em ordem):

- **Independete:** Nenhuma correlação entre as observações repetidas.
- **Simetria Composta:** Todas as observações dentro de um indivíduo têm a mesma correlação.
- **AR(1):** As observações mais próximas no tempo têm maior correlação.
- **Não Estruturada:** A correlação entre cada par de observações é estimada de forma independente.

c)

FAZER

d)

Primeiro podemos observar a estrutura da matriz de correlação da base como um todo e depois de cada grupo. Abaixo temos a matriz de correlação geral da base:

```
dados_largo <- reshape::cast(dados_rats, subject ~ time, value = "response")
dados_largo <- na.omit(dados_largo)
round(cor(dados_largo[,2:7]),2)
```

```
      [,1] [,2] [,3] [,4] [,5] [,6]
[1,] 1.00 0.61 0.60 0.72 0.64 0.70
[2,] 0.61 1.00 0.88 0.80 0.80 0.76
[3,] 0.60 0.88 1.00 0.86 0.76 0.72
[4,] 0.72 0.80 0.86 1.00 0.67 0.79
[5,] 0.64 0.80 0.76 0.67 1.00 0.75
[6,] 0.70 0.76 0.72 0.79 0.75 1.00
```

E para os diferentes grupos:

FAZER

Questão 3

a)